

Derin U-Net Ağ Mimarileri Kullanarak Yüzey Hata Tespiti

Surface Defect Detection Using Deep U-Net Network Architectures

Hüseyin ÜZEN

Bilgisayar Mühendisliği, Bingöl
Üniversitesi, Bingöl, Türkiye
huzen@bingol.edu.tr

Muammer TÜRKOĞLU

Yazılım Mühendisliği, Samsun
Üniversitesi, Samsun, Türkiye
muammer.turkoglu@samsun.edu.tr

Davut HANBAY

Bilgisayar Mühendisliği, İnönü
Üniversitesi, Malatya, Türkiye
davut.hanbay@inonu.edu.tr

Özetçe—Çelik, kumaş ve mermer gibi endüstride kullanılan ürünlerde oluşan yüzey hatalarının tespiti, ürün kalitesinin artırılması ve maddi kayıpların önlenmesi bakımından oldukça önemlidir. Fakat yüzey hatalarının karmaşıklığı ve çeşitliliği gibi nedenlerden dolayı yüzey hatalarının otomatik bir şekilde tespit edilmesi oldukça zor bir problemdir. Bu çalışmada, yüzey hata tespiti için U-net tabanlı VGG16-Unet ve Resnet34-Unet ağ modelleri önerilmiştir. Önerilen model, derin anlamsal özniteliklerle beraber ilk katmanlardaki konumsal öznitelikleri bir arada kullanmıştır. Önerilen ağ modellerinde, Unet mimarisinin giriş parametreleri için VGG16 ve Resnet34 ağ mimarilerinin eğitilmiş ağırlıkları kullanmıştır. Deneysel çalışmalarda, MT ve AITEX veri kümeleri için en yüksek F1-skor değeri, önerilen Resnet34-Unet modeli ile sırasıyla %91.07 ve %94.67 olarak elde edilmiştir. Elde edilen sonuçlara göre, önerilen model kullanılarak arka plan ile benzerlik gösteren hatalı bölgeler başarılı bir şekilde ayrıldığı gözlenmiştir.

Anahtar Kelimeler — Yüzey Hata Tespiti; Öznitelik Çıkarma, Unet; Derin Öğrenme

Abstract— Surface defects detection in products used in industry such as steel, fabric and marble is very important in terms of increasing product quality and preventing financial losses. However, automatic surface defects detection is a very difficult problem due to the complexity and diversity of surface defects. In this study, U-net based VGG16-Unet and Resnet34-Unet network models are proposed for Surface defects detection. The proposed model used spatial features in the first layers together with deep semantic features. In the proposed network models, the trained weights of the VGG16 and Resnet34 network architectures were used for the input parameters of the Unet architecture. In experimental studies, the highest F1-score value for MT and AITEX data sets was obtained as 91.07% and 94.67%, respectively, with the proposed Resnet34-Unet model. According to the results, it was observed that the defective areas showing similarity with the background were successfully separated by using the proposed model.

Keywords — Surface Defects Detection; Feature Extraction; Unet; Deep Learning


I. GİRİŞ

Yüzey hataları, ürünün homojen ve düzenli yüzeyinde oluşan düzensiz anomaliler (anomalies) şeklinde tanımlanabilir [1]. Yüzey hataları; tekstil, seramik, beton, metal ve alüminyum

gibi farklı alanlarda farklı tanımları ve türleri vardır (Şekil 1) [2]. İmalat sanayisinde oluşan yüzey hataların denetlenmesi ve üreticinin yüzey hataları olmayan yüksek kalitede ürün sağlaması, tüketicinin güvenini sağlamaktadır. Ayrıca hatalı üretiminin sebep olduğu problemin erken fark edilmesi oluşabilecek maddi kayıpları engellemektedir [2, 3]. Bu nedenle imalat sanayisinde yüzey hataların tespitine büyük önem verilmiştir. Günümüzde yüzey hataların tespiti, genellikle insan gözetimi ile manuel olarak yapılmaktadır. Yapılan manuel denetimlerde oluşan yorgunluk ve dikkat dağınıklığı; doğruluk, gerçek zamanlı performans ve verimliliği oldukça kısıtlamaktadır.

Literatürde otomatik olarak yüzeydeki hataların tespiti için yüzeyin özelliğine bağlı olarak farklı çözümler önerilmiştir. Genel anlamda yüzey hata tespiti için geliştirilen yöntemler yapısal, istatistiksel, filtre, model ve öğrenme tabanlı olarak 5 gruba ayrılmaktadır [3]. İstatistiksel, yapısal, spektral ve model tabanlı yöntemlerde hatasız veya hatalı yüzeyi, Gradient [4], morfolojik filtreler [5], Gri Seviye Eş Oluşum Matrisi [6] Fourier [7] ve Gabor [8] gibi yöntemler ile modellenmiştir. Daha sonra görüntü ya da öznitelik karşılaştırma işlemleri yaparak yüzey hataları tespit edilmiştir. Öğrenme tabanlı yöntemler ise makine öğrenmesi yöntemleri (rastgele orman algoritmaları [9], destek vektör makineleri (DVM) [10]) kullanarak hatalı ve hatasız bölgelerin birbirinden farkını öğrenerek hata tespiti yapılmıştır. Bu yöntemlerin en büyük dezavantajı özniteliklerin manuel seçilmesidir. Bundan dolayı farklı bir yüzey için bu yöntemler başarısız olacaktır. Buna kıyasla derin öğrenme yapısını kullanarak hata tespiti yapan yöntemler daha başarılı olmuştur. [3, 11–13]. Junfeng vd. [13] kumaş hata tespiti için MobileNetV2 ağ mimarisi ile Unet mimarisini birleştirerek Mobile-Unet mimarisi önermiştir. Önerilen modelde Unet mimarisindeki encoder bölgesi MobileNetV2 ağ mimarisi ile değiştirilmiştir. Önerilen modelde parametre sayısı azaltılarak eğitim ve test zamanındaki hesaplama maliyetleri düşürülmüştür. Hu vd. [12] kumaş hatalarının tespiti için hatasız kumaş görüntüleri ile eğitilmiş bir GAN ağ mimarisi önermiştir. Bu mimarinin girişine verilen kumaş görüntüsünün GAN mimarisi aracılığıyla yeniden oluşturulmuştur. Daha sonra giriş ve elde edilen çıkış görüntüleri kıyaslanarak hatalı bölge tespiti yapılmıştır. Liu vd [14] desenli kumaş hatalarının tespiti için DeepLabv3 [15] ağ modeli kullanmıştır. Natarajan vd [16]

transfer öğrenme tabanlı bir model önermiştir. Önerilen ESA (Evrişimsel Sinir Ağları) modelinden elde edilen öznitelikler destek vektör makinesinde (DVM) sınıflandırma için kullanılmıştır.



Şekil 1. Kumaş(a), metal(b), alüminyum(c) ve yol(d) ile ilgili hatasız (1. sıradaki) ve yüzey hatası (2. sıradaki) içeren örnek görüntüler [2]

Günümüzde yüzey hatalarının tespiti için yapılan çalışmalara bakıldığında nesnenin konumsal (spatial details) bilgilerin önemli olduğu için geleneksel VGG ve Resnet gibi ağ mimarileri yerine Unet [17] gibi ağ mimarileri daha çok kullanılmıştır [14]. Bunun temel sebebi geleneksel ESA mimarilerin ardışık katmanlar sayesinde güçlü anlamsal (semantics details) öznitelikleri elde ederken konumsal bilgilerin kaybedilmesidir. 2015 yılında önerilen Unet [17] ağ mimarisi kullandığı ara bağlantı sayesinde ilk katmanlardaki öznitelikleri, son katmandaki öznitelikler ile birleştirerek kullanmıştır. Bu yaklaşım ile geliştirilen birçok ağ modeli segmentasyon alanında başarılı sonuçlar vermiştir.

Bu çalışmada yüzey hata tespiti için Unet tabanlı Resnet34-Unet ve VGG16-Unet modeli önerilmiştir. Önerilen modellerin başlangıç katmanları olarak Resnet34 [18] ve VGG16 [19] ağ mimarileri kullanılmıştır. Elde edilen sonuçlar literatürde yapılan çalışmalar ile kıyaslanmıştır. En yüksek başarı Resnet34-Unet modeli ile elde edilmiştir.

Çalışmanın kalan kısmı şu şekilde organize edilmiştir. 2. Bölümde Resnet34, VGG16 ve Unet ağ mimarileri detaylandırılmıştır. Bunun yanında bu bölümde deneysel çalışmalar için kullanılan veri kümesi ve modeller verilmiştir. Bölüm 3'te deneysel çalışmalar ve Bölüm 4'te sonuçlar verilmiştir.

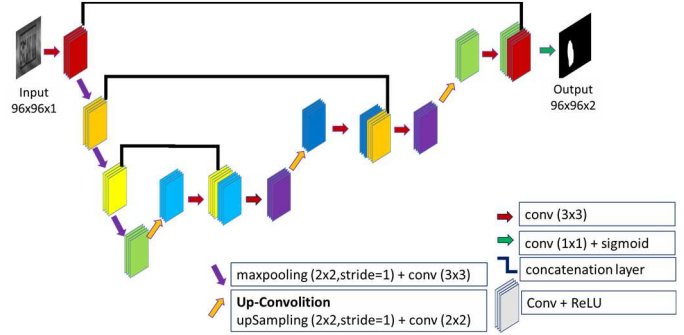
II. MATERYAL VE METOD

ESA (Evrişimsel Sinir Ağları) mimarileri ardışık evrişim, havuzlama, aktivasyon ve tam bağlı katmanlar içeren güçlü yapısı sayesinde birçok farklı problem için oldukça başarılı sonuçlar vermiştir. Segmentasyon veya yüzey hata tespiti için son zamanlarda en çok önerilen ve başarılı yöntemler Unet gibi tam bağlı evrişim katmanları içeren modeller olmuştur [3]. Bu modeller geleneksel ESA modellerinden farklı olarak tam bağlı katman (full connection layer) içermemekte ve ardışık evrişim, havuzlama, aktivasyon ve upsampling katmanlarından oluşmaktadır. Kullanılan evrişim, havuzlama ve aktivasyon katmanları geleneksel ESA mimarisi ile aynı yapıdadır. Evrişim katmanı, genel olarak bir filtreleme katmanıdır. Bu katman eğitim boyunca filtre ağırlıkları, problem için en uygun özniteliklere ulaşmak için güncellenmektedir. Bu yapı sayesinde elde edilen derin öznitelikler, problem için en uygun yapıda oluşmaktadır. Havuzlama katmanı, evrişim katmanları sonucunda elde edilen yüksek boyutlu veri küpünün boyutunu

indirmek için kullanılır. En yaygın kullanılan havuzlama katmanları maxPolling ve AveragePooling katmanlarıdır. Aktivasyon katmanları, veri küpünün doğrusalsızlık (Nonlinearlık) kazandırmak için uygulanır. En yaygın kullanılan ReLU, Leaky ReLU, sigmoid modelleridir. Unet gibi ağ modellerin geleneksel ESA modellerinden farklı olarak bulunan upsampling katmanı havuzlama katmanının aksine boyut yükseltme katmanıdır. Bu sayede ağ mimarisinin çıktısı görüntü ile aynı boyuta getirilmektedir. UpSampling, Up-Convolution, ve ConvTranspose gibi versiyonları bulunmaktadır [3, 17–19].

A. Unet

Geleneksel ESA mimarileri ardışık evrişim katmanları içerecek ağ mimarisinin derinlerine indikçe güçlü anlamsal öznitelik elde etmesini sağlamaktadır. Bunun yanında içerdiği havuzlama katmanları, öznitelik boyutunu düşürmesini sağlarken konumsal (spatial details) detaylar kaybolmaktadır. Unet mimarisi ilk katmanlardaki konumsal öznitelikleri daha fazla yararlanmak için ara bağlantı katmanları kullanarak ilk katmanlar ile son katmanlar birleştirilmiştir (şekil 2). Bu şekilde ilk katmanlarda elde edilen ve konum bilgisi açısından oldukça zengin özniteliklerden yararlanılmıştır. Şekil 2'de görüldüğü gibi her havuzlama katmanından önce bir ara bağlantı mevcuttur. Bu katmanlardan elde edilen öznitelikler ileriki ve kendisi ile aynı boyuttaki katman ile birleştirilmiştir. Unet ağ mimarisinin çıkış katmanı, görüntü ile aynı boyutta bir evrişim katman çıktısıdır. Unet mimarisinin son bölümünde veri küpünün boyutunu yükseltmek için Yukarı-Evrişim(Up-Convolution) katmanı kullanılmıştır. Bu katman ile şekil 3'te gösterildiği gibi gelen veri matrisinin boyutu artırılmıştır. Böylece boyut artırılırken hücredeki verileri tekrarlayarak çoğaltılmıştır. Daha sonra boyutu yükseltilmiş veri, bir evrişim işlemine alınmıştır. Bu şekilde havuzlama katmanının tersine gelen verinin boyutu iki katına çıkartılmıştır.



Şekil 2. Unet mimarisinin genel yapısı



Şekil 3. Yukarı-Evrişim(Up-Convolution) işlemin gösterimi

B. Resnet34-Unet ve VGG16-Unet ağ mimari

ESA modellerin yapısı gereği evrişim ve tam bağlı katmanlarında öğrenmesi gereken milyonlar seviyesindeki ağırlıkları vardır. Bu ağırlıkların en uygun değerlere getirilmesi için oldukça yüksek sayıda görüntü içeren güçlü bir eğitim veri kümesine ihtiyaç vardır. Fakat yüzey hata tespiti gibi

problemlerde böyle bir veri kümesi bulmak çoğu zaman imkânsızdır. Bu problem ile başa çıkmak için en yaygın kullanılan yöntemler önceden eğitilmiş bir ağ mimarisi kullanmak [16] veya veri kümesindeki örnek sayısını Veri Çoğaltma(VÇ, *Data augmentation*)[13] yöntemleri ile artırmaktır. VÇ yöntemleri genellikle görüntüyü çevirme, aynalama veya kırpmaya gibi yöntemler ile örnek sayısının artırılmasıdır. VÇ yöntemleri her ne kadar veri kümesindeki örnek sayısını artırsa da özellikle sınıflar arası benzerliğin çok olduğu problemlerde bu yöntemler yetersiz kalabilmektedir [13]. Ayrıca yüzey hatası gibi küçük boyutlarda olan ve arka plan ile çok benzerlik gösteren problemlerde negatif örneklerin kaybolmasına veya bulanıklaştırma gibi VÇ yöntemlerinde yüzey hatasının ayıramaz hale getirmesine sebep olabilmektedir. Bu durumlarda önceden eğitilmiş bir ağ mimarisinin kullanılması daha çok avantaj sağlayacaktır. Bu çalışmada yüzey hata tespiti için ImageNet veri kümesi ile önceden eğitilmiş VGG ve Resnet mimarileri, Unet ağ mimarisi ile birleştirilmiştir. Bunun için VGG16 ve Resnet34 mimarilerin son katmanlardaki tam bağlı katmanlar çıkartılmıştır. Geri kalan katmanlar aynı şekilde kullanılmıştır. VGG16 ve Resnet34 ağ mimarilerinin bitiminden sonra upsampling katmanları eklenmiştir. Birleştirme katmanları oluşturmak için bu ağ mimarilerinin her havuzlama katmanından önceki katman Şekil 2’de gösterildiği gibi kendisi ile aynı boyuttaki ileriki katman ile birleştirilmiştir.

C. Veri Kümesi

Bu çalışmada yüzey hata tespiti için MT [20] ve AITEX [21] veri kümeleri kullanılmıştır. MT veri kümesi manyetik kara (magnetic tile) yüzeylerinde oluşan 5 farklı hata tipini içeren toplam 1344 görüntüden oluşmaktadır. AITEX veri kümesi ise kumaş yüzeyinde oluşan 12 farklı hata tipi ve toplam 245 görüntüden oluşmaktadır. Tüm görüntüler 96x96 boyutuna indirgemıştır. Her bir veri kümesi % 75 Eğitim ve %25 test olacak şekilde ayrılmıştır. ESA modellerinin daha yüksek başarı elde etmesi için eğitim veri kümesindeki her bir örnek, çevirme, yansıma, kırpmaya gibi VÇ işlemlerine alınarak 8 katına çıkartılmıştır.

III. UYGULAMALAR

Bu çalışmada yüzey hata tespiti için Resnet34-Unet ve VGG16-Unet ağ mimarilerin Resnet34 ve VGG16 ağ mimarilerinin önceden eğitilmiş parametreleri kullanılmıştır. Daha sonra Resnet34-Unet ve VGG16-Unet mimarileri tekrar bir eğitim sürecine alınmıştır. Kullanılan modeller MT ve AITEX veri kümeleri üzerinden kapsamlı deneysel çalışmalar yapılmıştır. Yapılan deneysel çalışmalar i9 işlemci 32 GB ram ve RTX2080Ti(11GB) ekran kartına sahip bilgisayarda gerçekleştirmiştir. Kodlamalar Python içerisindeki Keras, TensorFlow ve segmentation_models [22] kütüphaneleri kullanılmıştır. Ağ mimarilerin eğitimi için BatchSize değeri 16 alınmıştır. Parametrelerin eğitimi için Adam optimizasyon yöntemi kullanılmıştır. Öğrenme oranı başlangıç olarak 0.01 verilmiş ve adım (epoch) sayısı 350 olarak belirlenmiştir. TensorFlow kütüphanesindeki doğru öğrenme oranı belirlemek için ReduceLROnPlateau ve yeterli adım sayısını belirlemek için EarlyStopping modeli kullanılmıştır.

ReduceLROnPlateau modeli eğitim sırasında belli adım sayısınca (patience) kayıp değerinde (loss) bir düşüş

olmadığında öğrenme oranını factor (0.1) değeri ile çarparak belli oranda düşürmektedir. EarlyStopping modeli ise aynı şekilde belli adım sayısı kadar(patience) kayıp değerinin azalmadığı durumda eğitimi bitirmektedir. Bu çalışmada ReduceLROnPlateau modeli için factor=0.1 ve patience=3 olarak alınmıştır. EarlyStopping modeli için patience değeri 8 alınmıştır. Deneysel çalışmalarda IoU(Birlik üzerinde kesişim (Intersection over Union), f1-skor(f1-score), kesinlik(precision), duyarlılık(recall) ve doğruluk(accuracy) metrikleri kullanılmıştır.


A. MT Sonuçları

Tablo 1’de MT veri kümesi kullanılarak elde edilen test sonuçları verilmiştir. Buradaki sonuçlara bakıldığında Resnet34-Unet modeli ile yapılan test çalışmasında %91.92 f1- skor ile en yüksek sonuç elde edilmiştir. İkinci en yüksek başarı VGG16-Unet modeli kullanılarak elde edilmiştir. Önerilen iki modelde PGA-Net [3] ve DFF [23] modelinden daha yüksek IoU değerleri elde etmiştir. U-net mimarisinin yapısındaki ara bağlantılar, yüzey görüntülerindeki küçük boyutlardaki hatalı bölgeleri bile başarılı bir şekilde tespit etmesini sağlamıştır.

TABLO 1. MT VERİ KÜMESİ KULLANILARAK ELDE EDİLEN BAŞARI SONUÇLARI

Model	IoU	F1-Skor	Kesinlik	Duyarlılık	Doğruluk
Resnet34-Unet	85.17	91.07	92.81	89.90	98.16
VGG16-Unet	81.16	87.94	90.30	86.01	97.70
PGA-Net[3]	71.31	-	78.7	89.5	-
DFF [21]	73.7	82.2	78.7	89.5	-

Şekil 4’te Resnet34 ve VGG16 öğrenmiş parametrelerini kullanan Unet modellerin öğrenme süresi boyunca f1-skör sonuçları verilmiştir. Resnet34 öğrenme parametrelerini kullanan Resnet34-Unet modeli 153 adımda eğitimi tamamlarken VGG öğrenme parametreleri kullanan VGG16-Unet modeli 146 adımda eğitimi tamamlamıştır. Bu çalışmada kullanılan EarlyStopping modeli eğitimi erken bitirmesi ile gereksiz yere yaklaşık 200 adım daha eğitim yapılmasını engellemiştir. Yüzey hata tespiti için kullanılan MT veri kümesinde, milyonlarca örnek içeren ImageNet [24] veri kümesine karşı çok az sayıda örnek içermektedir. Buna rağmen Resnet34 ve VGG16 ağ mimarilerinin başlangıç parametrelerini kullanılması, Resnet34-Unet ve VGG16-Unet modellerinin başarılı bir eğitimden geçmesini sağlamıştır (Şekil 4).



Şekil 4. MT veri kümesinde Resnet34-Unet ve VGG16-Unet mimarilerinin eğitim boyunca f1-skör sonuçları

B. AITEX Sonuçları

AITEX kumaş veri kümesindeki test sonuçları Tablo 2’de verilmiştir. Tablo 2’deki sonuçlara bakıldığında yöntemlerin sıralaması MT veri kümesi ile aynı olmuştur. En yüksek değeri %94.67 f1-skor ile Resnet34-Unet modeli kullanılarak elde edilmiştir. AITEX veri kümesinin paylaşıldığı makaledeki [21] elde edilen kesinlik ve doğruluk sonuçları ile kıyaslandığında önerilen Resnet34-Unet ve VGG16-Unet modeli kullanılarak daha yüksek başarı elde edilmiştir.

TABLO 2. AITEX KUMAŞ VERİ KÜMESİ KULLANILARAK ELDE EDİLEN BAŞARI SONUÇLARI

Model	IoU	F1-Skor	Kesinlik	Duyarlılık	Doğruluk
Resnet34-Unet	90.25	94.67	94.95	94.40	98.84
VGG16-Unet	89.01	93.92	94.50	93.37	98.87
AITEX Test1 [21]	-	-	-	78.10	88.98
AITEX Test2 [21]	-	-	-	89.67	87.76

IV. SONUÇ

Bu çalışmada, yüzey hata tespiti için Unet tabanlı Resnet34-Unet ve VGG16-Unet modelleri önerilmiştir. Önerilen modellerin başlangıç parametreleri için VGG16 ve Resnet34 ağ mimarilerinin eğitilmiş parametreleri kullanılmıştır. Önerilen modelde geleneksel ESA mimarilerinden farklı olarak derin anlamsal (semantics details) özniteliklerin yanı sıra ilk katmanlardaki konumsal (spatial details) öznitelikler birleştirilmiştir. Bunun sonucunda bu model, arka plan ile benzerlik gösteren hatalı bölgeleri başarılı bir şekilde ayırabilmiştir. Önerilen model, MT ve AITEX veri kümeleri üzerinden detaylı bir eğitim ve test çalışmalarından geçirilmiştir. Elde edilen sonuçlara göre, MT ve AITEX veri kümeleri için Resnet34-Unet mimarisi ile sırasıyla %91.07 ve %94.67 F1-Skor değerleri elde edilmiştir. Ayrıca, MT ve AITEX veri kümeleri için VGG16-Unet mimarisi kullanılarak sırasıyla %87.94 ve %93.92 F1-Skor değerleri elde edilmiştir. Deneysel sonuçlarda, önerilen modeller, literatürde var olan çalışmalara göre daha yüksek başarı elde edildiği gözlenmiştir.

KAYNAKLAR

- [1] Ma, B., Zhu, W., Wang, Y., Wu, H., et al., The defect detection of personalized print based on template matching, in: *2017 IEEE International Conference on Unmanned Systems (ICUS)*, IEEE, 2017, pp. 266–271.
- [2] Liu, J., Song, K., Feng, M., Yan, Y., et al., Semi-supervised anomaly detection with dual prototypes autoencoder for industrial surface inspection. *Opt. Lasers Eng.* 2021, *136*, 106324.
- [3] Dong, H., Song, K., He, Y., Xu, J., et al., PGA-Net: Pyramid Feature Fusion and Global Context Attention Network for Automated Surface Defect Detection. *IEEE Trans. Ind. Informatics* 2020, *16*, 7448–7458.
- [4] Sari-Sarraf, H., Goddard, J.S., Vision system for on-loom fabric inspection. *IEEE Trans. Ind. Appl.* 1999, *35*, 1252–1259.
- [5] Mak, K.L., Peng, P., Lau, H.Y.K., Optimal morphological filter design for fabric defect detection, in: *Proceedings of the IEEE International Conference on Industrial Technology*, 2005, pp. 799–804.
- [6] Bi, M., Sun, Z., Li, Y., Textural fabric defect detection using adaptive quantized Gray-level Co-occurrence Matrix and Support Vector Description Data. *Inf. Technol. J.* 2012, *11*, 673–685.
- [7] Hanbay, K., Talu, M.F., Özgüven, Ö.F., Fabric defect detection systems and methods—A systematic literature review. *Optik (Stuttg.)* 2016, *127*, 11960–11973.
- [8] Bissi, L., Baruffa, G., Placidi, P., Ricci, E., et al., Automated defect detection in uniform and structured fabrics using Gabor filters and PCA. *J. Vis. Commun. Image Represent.* 2013, *24*, 838–845.
- [9] Loonkar, M.S., Mishra, D.S., Analysis of Defect Classification Approaches for Fabric Images based on Four DFT Sector Features, in: *2019 International Conference on Advances in Computing, Communication and Control (ICAC3)*, IEEE, 2019, pp. 1–5.
- [10] Ghorai, S., Mukherjee, A., Gangadaran, M., Dutta, P.K., Automatic defect detection on hot-rolled flat steel products. *IEEE Trans. Instrum. Meas.* 2013, *62*, 612–621.
- [11] Uzen, H., Turkoglu, M., Hanbay, D., Texture defect classification with multiple pooling and filter ensemble based on deep neural network. *Expert Syst. Appl.* 2021, *175*, 114838.
- [12] Hu, G., Huang, J., Wang, Q., Li, J., et al., Unsupervised fabric defect detection based on a deep convolutional generative adversarial network. *Text. Res. J.* 2020, *90*, 247–270.
- [13] Jing, J., Wang, Z., Rätsch, M., Zhang, H., Mobile-Unet: An efficient convolutional neural network for fabric defect detection. *Text. Res. J.* 2020, 004051752092860.
- [14] Liu, J., Wang, C., Su, H., Du, B., et al., Multistage GAN for Fabric Defect Detection. *IEEE Trans. Image Process.* 2020, *29*, 3388–3400.
- [15] Chen, L.-C., Papandreou, G., Schroff, F., Adam, H., Rethinking Atrous Convolution for Semantic Image Segmentation. *ArXiv* 2017.
- [16] Natarajan, V., Hung, T.Y., Vaikundam, S., Chia, L.T., Convolutional networks for voting-based anomaly classification in metal surface inspection, in: *Proceedings of the IEEE International Conference on Industrial Technology*, Institute of Electrical and Electronics Engineers Inc., 2017, pp. 986–991.
- [17] Ronneberger, O., Fischer, P., Brox, T., U-Net: Convolutional Networks for Biomedical Image Segmentation, in: *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer Verlag, 2015, pp. 234–241.
- [18] He, K., Zhang, X., Ren, S., Sun, J., Deep Residual Learning for Image Recognition, in: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, 2016, pp. 770–778.
- [19] Simonyan, K., Zisserman, A., Very Deep Convolutional Networks for Large-Scale Image Recognition. *Inf. Softw. Technol.* 2014, *51*, 769–784.
- [20] Huang, Y., Qiu, C., Yuan, K., Surface defect saliency of magnetic tile. *Vis. Comput.* 2020, *36*, 85–96.
- [21] Silvestre-Blanes, J., Albero-Albero, T., Miralles, I., Pérez-Llorens, R., et al., A Public Fabric Database for Defect Detection Methods and Results. *Autex Res. J.* 2019, *Vol. 19*.
- [22] Yakubovskiy, P., “Segmentation Models.” https://github.com/qubvel/segmentation_models (accessed Feb. 26, 2021).
- [23] Cao, J., Yang, G., Yang, X., A Pixel-Level Segmentation Convolutional Neural Network Based on Deep Feature Fusion for Surface Defect Detection. *IEEE Trans. Instrum. Meas.* 2021, *70*.
- [24] “ImageNet.” <http://image-net.org/index> (accessed Feb. 27, 2021).