

# 基于小波域隐马尔可夫模型多尺度图像分割

张骥祥<sup>1,2</sup>, 戴居丰<sup>1</sup>, 郑宏兴<sup>2</sup>

(1. 天津大学电子信息工程学院, 天津 300072; 2. 天津工程师范学院, 天津 300222)

**摘 要:** 提出了一种基于小波域自适应上下文结构的多尺度图像分割算法 (JACMS)。该算法为了减小计算复杂度, 采用隐马尔可夫半树模型和参数加权训练算法, 得到了可靠的初始分割。为了获得较好的区域一致性和边缘准确性, 在进行尺度间融合时, 采用自适应的上下文结构分别应用于图像纹理均质区域和图像纹理边缘, 保证了图像大致轮廓的准确性和可靠性, 提高了分割后图像纹理边缘的精确度。对合成图像与航摄像片的实验结果表明, 该方法的分割错误概率低于传统的基于小波域隐马尔可夫树模型的图像分割方法, 且对真实图像得到了理想的分割效果。

**关键词:** 小波变换; 隐马尔可夫树模型; 纹理; 图像分割

中图分类号: TN911.73

文献标志码: A

文章编号: 0493-2137 (2008) 05-0611-05

## Multiscale Image Segmentation Using Wavelet-Domain Hidden Markov Model

ZHANG Ji-xiang<sup>1,2</sup>, DAI Ju-feng<sup>1</sup>, ZHENG Hong-xing<sup>2</sup>

(1. School of Electronic Information Engineering, Tianjin University, Tianjin 300072, China;

2. Tianjin University of Technology and Education, Tianjin 300222, China)

**Abstract:** An image segmentation algorithm based on wavelet-domain, referred to as joint adaptive context and multiscale segmentation (JACMS) was developed. Towards achieving lower computational complexity, we proposed a half hidden Markov tree (HMT) model and a weighting training algorithm. The technique provided a reliable initial segmentation when applied to image segmentation. In order to ensure high accuracy of both texture classification and boundary localization during the interscale fusion, adaptive context structures were applied to homogeneous regions and texture boundaries respectively. Experimental results of the segmentation for both synthetic images and aerial photo indicate that the approach has lower miss classified probability than traditional wavelet-domain HMTseg method, and it can achieve satisfying segmentation of real images.

**Keywords:** wavelet transform; hidden Markov tree model; texture; image segmentation

近年来, 小波域隐马尔可夫模型在图像处理与分析中得到了越来越广泛的应用。Crouse 等人<sup>[1]</sup>提出了一种小波域隐马尔可夫树 (half hidden Markov tree, HMT) 模型。该模型充分考虑了小波变换的 2 个重要特性—尺度内的聚集性和尺度间的持续性, 从而准确刻画了图像数据小波变换的统计特性。Choi 等人<sup>[2]</sup>利用此模型推导出一种基于 HMT 模型的图像分割方法, 即 HMTseg。其基本思想是利用 HMT 模型得到与图像各个尺度上数据块相对应的不同纹理相似

度, 然后通过比较相似度大小, 获得图像各个尺度上的初始分割, 再利用图像上下文信息逐步由粗尺度到细尺度融合相邻两尺度的初始分割结果, 最终得到细尺度级分割。

在采用 HMTseg 方法得到的各个尺度的初始分割结果中, 较粗尺度的分割结果有效地获取了图像不同纹理区域的主体轮廓, 但另一方面却丢弃了图像不同纹理区域之间的局部边缘细节; 而较细尺度的分割结果则在很大程度上弥补了这一损失。由于 HMTseg

收稿日期: 2007-07-13; 修回日期: 2008-02-21。

基金项目: 国家自然科学基金资助项目 (60671009)。

作者简介: 张骥祥 (1966—), 博士研究生, jixiang.zhang@163.com。

通讯作者: 戴居丰, jufengdai@tju.edu.cn。

方法直接融合各个尺度上的初始分割结果,且其中的上下文模型只考虑了上一较粗尺度的分割结果,所以其融合结果具有很大的依赖性,不能有效地保留图像的局部边缘细节.为了解决这一问题,同时也为了解决 HMT 模型 EM 训练<sup>[3-4]</sup>收敛慢的问题,提出了一种 HMT 半树模型参数加权训练算法,提高了小波域 HMT 模型训练的收敛速度.同时,采用不同的上下文模型应用于图像纹理的均质区域和图像纹理的边缘,通过简单的投票方法,由粗尺度到细尺度融合尺度间的初始分割结果,得到了很好的分割效果.

## 1 小波变换

由于 Haar 小波变换的二进制结构与多尺度图像分割的二维数据块的 4 叉树结构相对应(如图 1 所示),所以笔者采用 Haar 小波变换.




图 1 图像的多尺度结构  
Fig. 1 Multiscale structure of images

对一个图像进行二维 Haar 小波变换,可以解释为利用 4 个二维小波滤波器对图像进行滤波.这 4 个小波滤波器分别为局部平滑滤波器、水平边缘检测滤波器、垂直边缘检测滤波器和对角边缘检测滤波器,它们的表达式为

$$h_{LL} = 1/2 \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \quad (1)$$

$$g_{LH} = 1/2 \begin{pmatrix} 1 & 1 \\ -1 & -1 \end{pmatrix} \quad (2)$$

$$g_{HL} = 1/2 \begin{pmatrix} 1 & -1 \\ 1 & -1 \end{pmatrix} \quad (3)$$

$$g_{HH} = 1/2 \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} \quad (4)$$

要计算一个由  $2^J \times 2^J$  ( $J$  为尺度个数) 个像素组成的图像  $X$  的小波变换,首先需令平滑图像  $\mu_j(k, l) = X(k, l)$ ,  $k \geq 0, l \leq 2^j - 1$ .  $\mu_j(k, l)$  分别与 4 个滤波器  $h_{LL}$ 、 $g_{LH}$ 、 $g_{HL}$ 、 $g_{HH}$  作卷积,下抽样后,得到大小为  $2^{j-1} \times 2^{j-1}$  的子带图像,然后再对平滑图像  $\mu_{j-1}$  重复以上过程  $J-1$  次,最终得到  $\mu_0$ 、 $w_0^{LH}$ 、 $w_0^{HL}$ 、 $w_0^{HH}$ . 其中的尺度系数矩阵  $\mu_j$  ( $0 \leq j \leq J$ ) 是由原

始图像逐步平滑得到的.小波系数矩阵  $w_j^{LH}$ 、 $w_j^{HL}$ 、 $w_j^{HH}$  ( $0 \leq j \leq J-1$ ) 分别对应图像在水平、垂直、对角 3 个方向的小波系数.小波系数的树状结构如图 2 所示.




图 2 小波系数的树状结构  
Fig. 2 Quad-tree of wavelet coefficients

## 2 小波域 HMT 模型

图像的小波变换有 2 个基本统计特性: 小波系数的非高斯分布特性,即只有极少数小波系数是显著的,而绝大多数小波系数值是非常小的; 尺度间小波系数状态的马尔可夫依赖性,即小波系数“大”或“小”的状态具有在尺度间传递的特性.小波域 HMT 模型准确地刻画了小波变换的 2 个基本特性.

小波域 HMT 模型如图 3 所示.图 3 中,实心点表示小波系数,空心点表示小波系数的状态.每一个小波系数对应一个隐状态,隐状态潜在地控制着小波系数值的大小.为叙述方便,做如下约定:小波系数用  $w_i$  表示,隐状态用  $s_i$  表示,根节点处的小波系数记作  $w_1$ ,根节点处的隐状态记为  $s_1$ ,以  $\rho(i)$  表示节点  $i$  的父节点.




图 3 小波域 HMT 模型  
Fig. 3 Wavelet-domain HMT model

每个小波系数的非高斯分布特性以二状态高斯混合模型(Gauss mixture model, GMM)来刻画,总体概率密度函数为

$$f(w_i) = \sum_{m=S,L} p_{s_i}(m) f(w_i | s_i = m) \quad (5)$$

式中:  $p_{s_i}(m)$  表示小波系数状态  $s_i$  为  $m$  的概率 ( $m$  有大小 2 种状态,即  $m = S, L$ );  $f(w_i | s_i = m)$  表示  $w_i$

状态为  $m$  时的高斯条件概率。

尺度间小波系数状态的马尔可夫依赖性由状态转移概率矩阵  $\varepsilon_{i,\rho(i)}^{mn}$  来描述,  $m$  和  $n$  分别表示父节点和子节点的状态,  $\varepsilon_{i,\rho(i)}^{mn}$  反映了 Markov-1 链粗、细尺度间的转移概率, 即

$$\varepsilon_{i,\rho(i)}^{mn} = \begin{bmatrix} \varepsilon_{i,\rho(i)}^{SS} & 1 - \varepsilon_{i,\rho(i)}^{SS} \\ 1 - \varepsilon_{i,\rho(i)}^{LL} & \varepsilon_{i,\rho(i)}^{LL} \end{bmatrix} \quad (6)$$

若小波系数用  $m$  个状态的混合高斯模型对每个小波系数建模, 则 HMT 模型的参数如下:

(1) 根节点状态变量  $s_i$  的状态概率分布函数  $p_{s_i}(m)$ ;

(2) 所有父、子节点的状态转移概率, 即已知父节点  $\rho(i)$  的状态变量  $s_{\rho(i)}$  的值为  $n$  时, 子节点状态变量  $s_i$  的值为  $m$  的条件概率  $\varepsilon_{i,\rho(i)}^{mn}$ ;

(3) 每一节点的小波系数  $w_i$  对应的不同状态下的均值  $\mu_{i,m}$  和方差  $\sigma_{i,m}^2$ 。

把这些参数归为一个模型参数矢量, 则模型参数集为

$$\Theta = \{p_{s_i}(m), \varepsilon_{i,\rho(i)}^{mn}, \mu_{i,m}, \sigma_{i,m}^2 \mid i = 1, 2, \dots, P; m, n = S, L\} \quad (7)$$

式中  $P$  表示小波系数节点个数。式 (7) 说明, 在小波 HMT 模型中, 每个小波系数由 4 个参数描述, 它们共同构成 HMT 参数集。

### 3 自适应上下文结构多尺度分割

#### 3.1 HMT 模型训练

在对图像进行分割前, 首先要通过训练得到图像中每一类纹理  $C \in \{1, 2, \dots, N_c\}$  的 HMT 模型参数  $M_c$ 。训练图像的产生通常有 2 种方法: 直接从待处理图像中截取一些块作为训练图像; 用其他不同的但统计特性相似的图像来进行训练。

HMT 的训练通常采用 EM 算法。EM 算法每迭代一次的计算量为  $O(n)$  ( $n$  为图像像素数), 对于 HMT, EM 算法收敛于对数似然函数  $f(W|\Theta)$  的局部最大值, 迭代步骤如下。

(1) 初始条件, 即选择一个初始模型, 估计  $\Theta^0$ , 设置迭代数  $l=0$ 。

(2) E 步, 计算对数似然函数的数学期望值, 即

$$Q(\Theta|\Theta^l) = E[\ln f(W, S|\Theta) | W, \Theta^l] \quad (8)$$

(3) M 步, 根据式 (9) 更新参数, 即

$$\Theta^{l+1} = \arg \max_{\Theta} Q(\Theta|\Theta^l) \quad (9)$$

(4) 令  $l=l+1$ , 若收敛, 则停止, 否则回到 E 步。

HMT 半树模型参数加权训练算法采用 3 种方法减少计算量。第一, 由于粗尺度的小波系数对应大的图像数据块, 其中可能包括不同类别的纹理, 所以可把 HMT 树剪短, 去掉上半部分, 保留下半部分。下半部分变成许多小的 HMT, 这些 HMT 具有相同的参数矢量  $\Theta$ , 这样训练变成了对一个小的 HMT 模型进行参数估计, 减少了训练数据  $n$ , 从而减少了计算量。第二, 假设 HMT 模型中各尺度内的小波系数具有相同的统计分布, 则 HMT 模型参数的数目从大约  $4n$ , 降低到大约  $4J$ , 实现尺度内“绑定”。第三, 对 HMT 模型进行训练时, 对参数矢量  $\Theta$  中的参数  $\mu_{i,m}$ 、 $\sigma_{i,m}^2$  加权, 大大提高了 HMT 模型 EM 训练的收敛速度。通过实验得到权值必须在 50~300 内, 迭代次数可在 6~30 之间任意选择。

#### 3.2 似然函数计算

假设给定已经训练好的图像中每一类纹理  $C \in \{1, 2, \dots, N_c\}$  的 HMT 模型参数为  $M_c = \{\Theta_c^{LH}, \Theta_c^{HL}, \Theta_c^{HH}\}$ , 待分图像的小波变换系数为  $W$  (被观测数据集), 子树  $T_i$  的根节点为  $w_i$ , 则可通过 EM 算法中一次简单的从树叶到树根上向运算计算出条件似然  $\beta_i(m) = f(T_i | s_i = m, \Theta_c)$ , 于是可计算出似然函数

$$f(T_i | \Theta_c) = \sum_{m=S,L} \beta_i(m) p_{s_i}(m) \quad (10)$$

图像数据块  $d_i$  对应 3 棵子树  $\{T_i^{LH}, T_i^{HL}, T_i^{HH}\}$ , 通过 3 次 HMT 的上向运算得到每个子树的似然函数值。假设小波系数的 3 个子带之间是相互独立的, 则数据块  $d_i$  总的似然函数值为

$$f(d_i^j | M_c) = f(T_i^{HH} | \Theta_c^{HH}) \cdot f(T_i^{HL} | \Theta_c^{HL}) f(T_i^{LH} | \Theta_c^{LH}) \quad (11)$$

$f(d_i^j | M_c)$  表示模型参数匹配小波系数的程度, 根据最大似然估计 (ML) 准则, 即取似然函数最大的一组参数作为被观测小波系数的类别估计。于是, 得到待分割图像各个尺度上的初始分割。

#### 3.3 基于上下文模型的尺度间融合

3.2 节中讨论的分割算法提供的是不同尺度上的初始分割。相比较而言, 粗尺度上分割结果稳健, 细尺度则分割的分辨率高。为了提高分割精度, HMTseg 采用一种上下文模型进行尺度间的融合。 $j$  尺度上的图像子块  $d_i^j$  类属  $C_i^j$  除了依赖于  $j-1$  尺度上的父辈  $d_{\rho(i)}^{j-1}$  的类属  $C_{\rho(i)}^{j-1}$  外, 还要依赖于父辈  $d_{\rho(i)}^{j-1}$  的八邻域数据块的类属。因此, 对于某数据块属性的

确定是通过其自身关于 HMT 模型的似然值和父辈的属性来共同确定,上下文参数矢量  $\mathbf{v}_i^j$  是  $j-1$  尺度上的类别标签  $C_k^{j-1}$  的函数,则  $j$  尺度上的尺度融合结果为

$$\hat{C}_i = \arg \max_{C_i \in \{1,2,\dots,N_c\}} f(d_i^j | C_i^j) p(C_i^j | \mathbf{v}_i^j) \quad (12)$$

给定待分割图像,进行初始分割后,通过基于上下文的贝叶斯分类使后验概率  $p(C_i | d_i, \mathbf{v}_i)$  最大化<sup>[5]</sup>,从而确定图像子块  $d_i^j$  的类别标签. 从一个较粗尺度开始,通常数据块大小为  $8 \times 8$ ,向细尺度逐级重复基于上下文的尺度间融合算法,依次得到分辨率为  $4 \times 4$  数据块、 $2 \times 2$  数据块的图像精细分割结果.

如何最大限度地获取图像不同纹理区域主体轮廓的前提下有效地保留住局部边缘细节是融合尺度间初始分割结果的主要目标. 在 HMTseg 方法中,由于定义节点  $i$  上下文参数矢量  $\mathbf{v}_i^j$  是其父节点  $\rho(i)$  及父节点的八邻域的类别标签的函数,这就使得尺度间融合结果过度依赖于较粗尺度的分割结果,因而不能有效地保留图像的局部边缘细节.

笔者提出一种改进的自适应的上下文尺度间融合方法<sup>[6-7]</sup>. 这种多尺度融合策略不仅考虑了同一尺度所产生的像素类别比较的最大似然估计,而且还考虑了父子节点间类别的传递性,来改善 HMTseg 对初始分割的融合效果,其框图如图 4 所示.




图 4 自适应的上下文尺度间融合框图

Fig. 4 Schematic diagram of adaptive interscale fusion

以二纹理图像分割为例说明尺度间融合过程. 二纹理的类别标签有 2 个值,一类标签是 1,另一类标签是 0. 对图像进行初始分割后,得到了类别标签树. 要确定  $j$  尺度上的某一数据块  $d_i^j$  的属性,通过对  $j-1$  尺度上的父辈  $d_{\rho(i)}^{j-1}$  及其八邻域的类别进行投票推举(求和),来判断数据块  $d_i^j$  的属性,即是属于纹理的均匀区域还是属于纹理的边缘. 实际上,就是在  $j-1$  尺度类别标签矩阵上,用图 5 所示模板分别与各节点类别标签做卷积,以确定其 4 个子节点的属性.  $j-1$  尺度上某节点与模板做卷积求和后,值位于  $[0, 9]$  区间,可设求和值位于  $[0, 1]$ 、 $[8, 9]$  区间时其  $j$  尺度子节点属于图像纹理均质区域,求和值位于  $[3, 7]$  区间时其  $j$  尺度子节点属于图像纹理边缘区域.

1	1	1
1	1	1
1	1	1

图 5 确定数据块  $d_i^j$  属性的模板

Fig. 5 The mask used to determine the class of dyadic square  $d_i^j$

确定数据块  $d_i^j$  的最终类别,其上下文参数矢量  $\mathbf{v}_i^j$  共有 4 个参数,分别是  $d_i^j$  本身的类别标签  $L$ 、其八邻域的类别标签  $L_8$ 、其父节点的类别标签  $P$ 、父节点的八邻域类别标签  $P_8$ . 对 4 个参量分别加不同的权值  $Q_1$ 、 $Q_2$ 、 $Q_3$  和  $Q_4$ ,则构成了自适应的上下文矢量

$$\mathbf{v}_i^j = \{Q_1 L, Q_2 L_8, Q_3 P, Q_4 P_8\} \quad (13)$$

调整各权值,便得到均质区域模型和边缘区域模型.

#### 4 实验结果

将所提出的自适应上下文结构多尺度分割(joint adaptive context and multiscale segmentation, JACMS)算法与 HMTseg 图像分割算法进行比较实验. 图 6 给出了二类 Brodatz 纹理<sup>[8]</sup>合成图像应用 HMTseg 算法和 JACMS 算法的分割结果比较. 图 7 给出了航摄像片<sup>[9]</sup> JACMS 算法的分割结果. 实验中所使用的多尺度图像数据由训练图像和待分割测试图像经离散小波变换后的小波系数构成. 小波变换的基函数为 Haar 小波,各图像的大小均为  $256 \times 256$ ,自适应上下文模型参数邻域大小为  $3 \times 3$ .




图 6 合成图像的分割结果比较

Fig. 6 Comparison of the segmentation results between JACMS method and HMTseg




图 7 航摄像片分割结果

Fig. 7 Segmentation result of an aerial photo

### 1) 分割结果主观评价

观察图 6 (b) 和图 6 (c), 很容易发现 JACMS 算法分割后图像比 HMTseg 算法分割后图像边界清晰、大大减小了边界锯齿, 分割边缘准确性大大提高。观察图 7 可发现, JACMS 算法的分割后图像, 各纹理区域内部均匀性良好, 纹理间轮廓线非常平滑, 获得了清晰的视觉效果。因此, 分割后图像主观评价良好。

### 2) 分割结果客观评价

采用二纹理合成图像测试 HMTseg 算法和 JACMS 算法的性能。对比参考分割图, 计算出图像分割的平均错误率, 并作为图像分割的客观评价标准, 从而保证了分割评价的客观性和通用性。采用图像分割的平均错误率和图像多尺度统计模型训练迭代次数这 2 个指标来衡量比较 HMTseg 算法和 JACMS 算法性能, 比较结果见表 1。

表 1 HMTseg 算法和 JACMS 算法性能比较  
Tab.1 Comparison of the performance between HMTseg method and JACMS method

方法	模型训练迭代次数	图像分割平均错误率/%
HMTseg 算法	60	7.35
JACMS 算法	15	2.72

从表 1 可以看出, JACMS 算法进行 HMT 模型训练时, 迭代次数小于 HMTseg 算法, 图像分割结果的平均错误率也小于 HMTseg 算法, 说明 JACMS 算法比 HMTseg 算法减小了计算量, 且提高了分割的准确度。

## 5 结 语

基于隐马尔可夫树模型的多尺度图像分割 (HMTseg) 方法的主要缺点在于纹理边界分割精度低; 另外, 进行尺度间融合时, 上下文模型参数估计需要迭代, 计算量较大。笔者提出的纹理分割方法对此做了改进。首先, HMT 模型参数估计时, 采用 HMT 半树模型参数加权训练算法, 提高了 EM 训练的收敛速度; 其次, 采用了自适应的上下文结构模

型, 该模型无需迭代, 计算量小。实验结果表明, 本文中提出的图像分割方法分割精度要高于 HMTseg 分割方法, 且对合成纹理和自然界图像均有很好的分割效果。

### 参考文献:

- [1] Crouse M S, Nowak R D, Baraniuk R G. Wavelet-based statistical signal processing using hidden Markov models [J]. *IEEE Transactions on Signal Processing*, 1998, 46 (4): 886-902.
- [2] Choi H, Baraniuk R G. Multiscale image segmentation using wavelet-domain hidden Markov models [J]. *IEEE Transactions on Image Processing*, 2001, 10 (9): 1322-1331.
- [3] Ronen O, Rohlicek J, Ostendorf M. Parameter estimation of dependence tree models using the EM algorithm [J]. *IEEE Signal Processing Letters*, 1995, 2 (8): 157-159.
- [4] Rabiner L. A tutorial on hidden Markov models and selected applications in speech recognition [J]. *Proceedings of the IEEE*, 1989, 77 (2): 257-285.
- [5] Romberg J K, Choi H, Baraniuk R G. Bayesian tree-structured image modeling using wavelet-domain hidden Markov models [J]. *IEEE Transactions on Image Processing*, 2001, 10 (7): 1056-1068.
- [6] Fan Guoliang, Xia Xianggen. Wavelet-based texture analysis and synthesis using hidden Markov models [J]. *IEEE Transactions on Circuits and Systems-I: Fundamental Theory and Applications*, 2003, 50 (1): 106-120.
- [7] Fan Guoliang, Xia Xianggen. A joint multi-context and multiscale approach to Bayesian image segmentation [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2001, 39 (12): 2680-2688.
- [8] Randen T. The Brodatz Textures Image Database [EB/OL]. <http://www.ux.uis.no/~tranden/>, 2005-12-15.
- [9] The Usc-sipi Image Database [EB/OL]. <http://sipi.usc.edu/serices.html>, 2006-08-20.